

# **PROPOSAL PROYEK**

**11S4037 – PEMROSESAN BAHASA ALAMI**

## **Multi-label Emotion Classification using Bi-LSTM with GloVe Word Embedding**



### **Disusun oleh:**

<b>12S18004</b>	<b>Rosalia Pane</b>
<b>12S18008</b>	<b>Indah Tri Anastasya Manik</b>
<b>12S18011</b>	<b>Nadya Putri Tambunan</b>
<b>12S18043</b>	<b>Roy Gunawan napitupulu</b>
<b>12S18048</b>	<b>Rifka Uli Siregar</b>

**FAKULTAS INFORMATIKA DAN TEKNIK ELEKTRO  
INSTITUT TEKNOLOGI DEL**

**2021**

## DAFTAR ISI

DAFTAR TABEL.....	3
DAFTAR GAMBAR .....	4
BAB I PENDAHULUAN.....	5
1.1.    Latar Belakang.....	5
1.2.    Tujuan .....	7
1.3.    Manfaat .....	7
1.4.    Ruang Lingkup.....	7
BAB II ISI.....	8
2.1 Analisis .....	8
2.1.1 Analisis Data.....	8
2.1.2 Analisis Metode .....	10
DAFTAR PUSTAKA .....	1

## DAFTAR TABEL

Tabel 1. Atribut pada dataset .....	8
-------------------------------------	---

## **DAFTAR GAMBAR**

Gambar 1. Dsitribusi Label pada Dataset .....	10
---	----

# BAB I PENDAHULUAN

Bagian ini menyajikan latar belakang, tujuan, manfaat, dan ruang lingkup pengerjaan proyek.

## 1.1. Latar Belakang

Emosi adalah keadaan pikiran yang berlangsung terus-menerus, yang ditandai dengan gejala mental, fisik dan perilaku. Emosi seseorang dapat diidentifikasi secara langsung melalui ekspresi wajah dan ucapannya. Mendeteksi emosi secara otomatis sangat penting karena dapat diterapkan di berbagai bidang. Misalnya dalam dunia pendidikan, analisis emosi dapat dimanfaatkan untuk lingkungan *e-learning*. Selain itu, dalam bisnis yang digunakan untuk mengidentifikasi keluhan pelanggan [1].

Dari pengalaman sehari-hari, beberapa emosi tampaknya berbeda dan terjadi secara independen. Emosi yang secara inheren kontradiktif, seperti love dan hate mungkin memerlukan serangkaian kelas yang terpisah untuk mengakomodasikan aspek dari setiap kelas. Disisi lain, emosi yang identik biasanya berada dibawah valensi emosional yang sama dan sering muncul bersamaan dalam situasi tertentu. Oleh karena itu, berbagai emosi ini dapat dikelompokkan bersama. Deteksi emosi, yang berperan sebagai masalah klasifikasi multi-label dapat membantu menjelaskan sifat kompleks dari emosi yang terjadi bersamaan, sehingga memberikan pemahaman tentang karakteristik setiap emosi [2].

Pendeteksian emosi merupakan salah satu masalah yang muncul di bidang *Natural Language Processing* (NLP). NLP digunakan untuk memproses data seperti teks yang terstruktur maupun tidak menjadi pengetahuan bermakna untuk berbagai masalah bisnis. NLP telah banyak digunakan untuk solusi masalah seperti klasifikasi, pemodelan topik, *text generation*, *QA system*, rekomendasi, dan lainnya [3].

Baru-baru ini, masalah klasifikasi *multi-label* telah menarik minat yang cukup besar karena penerapannya ke berbagai *domain*, termasuk klasifikasi teks, klasifikasi adegan dan video, dan bioinformatika [4]. Berbeda dengan masalah klasifikasi tradisional label tunggal (yaitu, multi-kelas atau biner), di mana sebuah *instance* dikaitkan dengan hanya satu label dari satu set label yang terbatas, dalam masalah klasifikasi *multi-label*, sebuah *instance* dikaitkan dengan *subset* dari label [5].

Pendeteksian emosi menggunakan klasifikasi *multi-label* menjadi masalah karena suatu kalimat cenderung melibatkan lebih dari satu kategori emosi. Sehingga, tantangan utama yang muncul adalah bagaimana memodelkan ketergantungan antar label menggunakan pendekatan klasifikasi. Misalnya, emosi dengan label “*angry*” dan “*disgust*” memiliki ketergantungan daripada emosi “*sad*” dan “*joy*” yang saling bertentangan [6]. Analisis emosi melalui sebuah teks tampaknya juga menjadi tantangan karena faktanya bahwa ekspresi tekstual tidak selalu secara langsung melibatkan kata-kata yang berhubungan dengan emosi, tetapi seringkali suatu kalimat perlu dipahami untuk memberikan sebuah makna [7].

Salah satu pendekatan yang dapat digunakan untuk mengatasi masalah klasifikasi *multi-label* adalah metode *Bidirectional Long Short Term Memory* (Bi-LSTM). Metode Bi-LSTM merupakan perkembangan dari model LSTM dengan dua lapisan, dimana lapisan pertama bergerak maju (*forward*) untuk memahami dan memproses dari kata pertama menuju kata terakhir, demikian sebaliknya lapisan atasnya bergerak mundur (*backward*) untuk memahami dan memproses dari kata terakhir menuju kata pertama. Oleh karena itu, Bi-LSTM sangat baik digunakan untuk mengenali pola dalam kalimat, dikarenakan setiap kata dalam kalimat diproses secara sekuensial [8].

Kemudian dalam melakukan klasifikasi, metode Bi-LSTM akan digabungkan dengan salah satu pendekatan pembobotan kata yaitu *pre-trained word embeddings GloVe*. Dimana, *GloVe* merupakan salah satu pendekatan yang memiliki akurasi yang baik untuk memproses pembobotan kata dalam data dibanding model *word embeddings* lain seperti CBOW dan *skip-grams*. Secara keseluruhan, *GloVe* mengungguli model lain dalam hal analogi kata, kemiripan kata dan tugas *named entity recognition* [9].

Oleh karena itu, berdasarkan uraian dari permasalahan sebelumnya, penulis berfokus pada pengklasifikasian emosi *multi-label*, yang bertujuan untuk mengembangkan sistem otomatis untuk mengkategorikan kalimat ke dalam netral dan 27 emosi seperti *admiration*, *amusement*, *anger* dan emosi lainnya. Penggunaan pendekatan Bi-LSTM dan *word embedding GloVe* akan membantu dalam membentuk matriks *embedding* pada masalah klasifikasi *multi-label* dengan menggunakan *dataset GoEmotions* yang diperoleh dari *Hugging Face*.

## 1.2. Tujuan

Tujuan dari proyek *multi-label emotion classification* ini, antara lain:

1. Menerapkan metode *Bidirectional Long Short Term Memory* (Bi-LSTM) dengan *GloVe* sebagai *word embedding* dalam menganalisis teks apakah teks tersebut termasuk ke dalam teks dengan beberapa label (*multi-label*).
2. Untuk mengetahui bagaimana tingkat akurasi menggunakan metode *Bidirectional Long Short Term Memory* (Bi-LSTM) dengan *GloVe* sebagai *word embedding* dalam melakukan pengklasifikasian *multi-label*.

## 1.3. Manfaat

Berikut adalah manfaat dari pembuatan *multi-label emotion classification* menggunakan metode Bi-LSTM dan *GloVe* antara lain:

1. Mengetahui cara dan proses klasifikasi *multi-label emotion* menggunakan metode Bi-LSTM dan *GloVe* sebagai *word embedding*.
2. Mengetahui tingkat akurasi menggunakan metode Bi-LSTM dan *GloVe* sebagai *word embedding* dalam melakukan klasifikasi *multi-label emotion*.

## 1.4. Ruang Lingkup

Ruang lingkup dalam pengerjaan proyek ini yaitu menggunakan metode Bi-LSTM dan *word embedding GloVe* dengan menggunakan *dataset GoEmotions* yang diperoleh dari *Hugging Face* [10].

## BAB II ISI

Pada bab ini mencakup analisis yaitu analisis terhadap data dan analisis terhadap metode.

### 2.1 Analisis

Pada *subbab* ini dijelaskan analisis yang dilakukan terhadap data dan metode yang digunakan dalam pengimplementasian multi-label klasifikasi emosi.

#### 2.1.1 Analisis Data

*Dataset* yang digunakan dalam proyek ini menggunakan *dataset GoEmotions* yang diperoleh dari *Hugging Face* [10]. *Dataset GoEmotions* terdiri dari 43410 baris dan 37 kolom. *Dataset* tersebut telah diberikan beberapa kelas/label yaitu pada setiap teks dalam data tersebut. Pada Tabel 1 berikut menampilkan gambaran dari dataset yang digunakan yang terdiri dari nama atribut, tipe atribut dan keterangan.

Tabel 1. Atribut pada *dataset*

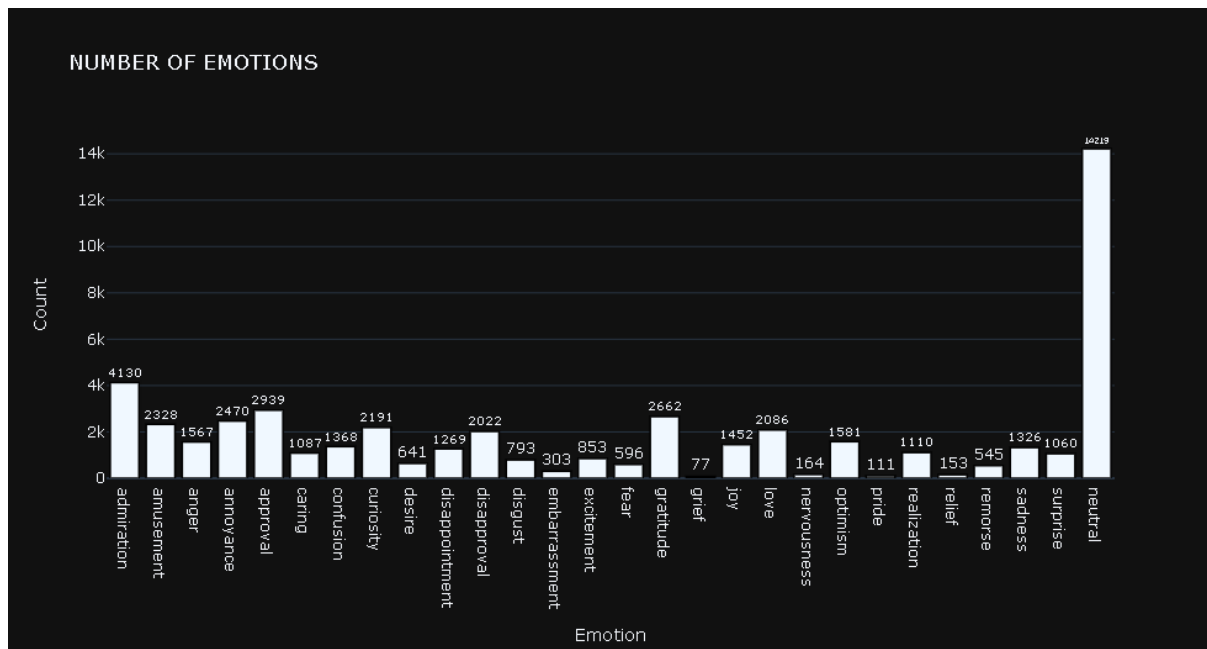
No	Nama Atribut	Tipe Atribut	Keterangan
1	<i>text</i>	Kategorikal	Komentar yang berasal dari Reddit
2	<i>id</i>	Kategorikal	Berisi id text
3	<i>author</i>	Kategorikal	Nama pengguna penulis komentar di Reddit
4	<i>subreddit</i>	Kategorikal	Subreddit tempat komentar berasal
5	<i>link_id</i>	Kategorikal	ID tautan komentar
6	<i>parent_id</i>	Kategorikal	ID <i>parent</i> dari komentar
7	<i>created_utc</i>	Numerik	<i>Timestamp</i> komentar
8	<i>rater_id</i>	Numerik	ID unik dari annotator
9	<i>example_very_unclear</i>	Kategorikal	Apakah annotator menandai label yang tidak jelas atau sulit untuk diberi label (dalam hal ini mereka tidak memilih label emosi)
10	<i>admiration</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>admiration</i> (1) dan <i>non-admiration</i> (0)
11	<i>amusement</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>amusement</i> (1) dan <i>non-amusement</i> (0)
12	<i>anger</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>anger</i> (1) dan <i>non-anger</i> (0)
13	<i>annoyance</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>annoyance</i> (1) dan <i>non-annoyance</i> (0)



14	<i>approval</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>approval</i> (1) dan <i>non-approval</i> (0)
15	<i>caring</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>caring</i> (1) dan <i>non-caring</i> (0)
16	<i>confusion</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>confusion</i> (1) dan <i>non-confusion</i> (0)
17	<i>curiosity</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>curiosity</i> (1) dan <i>non-curiosity</i> (0)
18	<i>desire</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>desire</i> (1) dan <i>non-desire</i> (0)
19	<i>disappointment</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>disappointment</i> (1) dan <i>non-disappointment</i> (0)
20	<i>disapproval</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>disapproval</i> (1) dan <i>non-disapproval</i> (0)
21	<i>disgust</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>disgust</i> (1) dan <i>non-disgust</i> (0)
22	<i>embarrassment</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>embarrassment</i> (1) dan <i>non-embarrassment</i> (0)
23	<i>excitement</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>excitement</i> (1) dan <i>non-excitement</i> (0)
24	<i>fear</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>fear</i> (1) dan <i>non-fear</i> (0)
25	<i>gratitude</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>gratitude</i> (1) dan <i>non-gratitude</i> (0)
26	<i>grief</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>grief</i> (1) dan <i>non-grief</i> (0)
27	<i>joy</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>joy</i> (1) dan <i>non-joy</i> (0)
28	<i>love</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>love</i> (1) dan <i>non-love</i> (0)
29	<i>nervousness</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>nervousness</i> (1) dan <i>non-nervousness</i> (0)
30	<i>optimism</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>optimism</i> (1) dan <i>non-optimism</i> (0)
31	<i>pride</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>pride</i> (1) dan <i>non-pride</i> (0)
32	<i>realization</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>realization</i> (1) dan <i>non-realization</i> (0)
33	<i>relief</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>relief</i> (1) dan <i>non-relief</i> (0)

34	<i>remorse</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>remorse</i> (1) dan <i>non-remorse</i> (0)
35	<i>sadness</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>sadness</i> (1) dan <i>non-sadness</i> (0)
36	<i>surprise</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>surprise</i> (1) dan <i>non-surprise</i> (0)
37	<i>neutral</i>	Kategorikal	Berisi pengelompokan <i>text</i> antara <i>neutral</i> (1) dan <i>non-neutral</i> (0)

Berikut adalah distribusi label pada *dataset* ditunjukkan pada Gambar 1.



Gambar 1. Dsistribusi Label pada *Dataset*

### 2.1.2 Analisis Metode

Pada klasifikasi kelas (seperti *binary* dan *multi-class*), *output* yang diterima akan tunggal dari beberapa opsi yang diberikan. *Binary class* akan memberikan kemungkinan kelas "N" sebanyak 2 ( $N = 2$ ) sementara *multi-class* akan memberi kemungkinan sebanyak  $N > 2$ . Berbeda dengan *Multi-label text classification*, jenis pengklasifikasian ini memprediksi beberapa kemungkinan label yang akan dilibatkan dalam teks tertentu. Artinya, *output* yang dihasilkan akan lebih dari satu.

*Bidirectional Long Short-Term Memory* (Bi-LSTM) adalah perkembangan dari model LSTM dimana terdapat dua lapisan yang prosesnya saling berkebalikan arah, model ini sangat baik untuk mengenali pola dalam kalimat karena setiap kata dalam kalimat diproses secara sekuensial. Dengan adanya lapisan dua arah yang saling berlawanan ini maka model dapat

memahami dan mengambil perspektif dari kata terdahulu dan kata terdepan, sehingga proses pembelajaran akan semakin dalam yang berdampak pada model akan lebih memahami konteks pada klasifikasi emosi tersebut. *GloVe* merupakan salah satu pendekatan yang memiliki akurasi yang baik untuk memproses pembobotan kata dalam data dibanding model *word embeddings* lain seperti CBOW dan *skip-grams*. Sehingga dalam melakukan klasifikasi, metode Bi-LSTM akan digabungkan dengan salah satu pendekatan pembobotan kata yaitu *pre-trained word embeddings GloVe*.

Analisis *multi-label emotion classification* pada komentar Reddit yang terdapat dalam *dataset GoEmotions* diklasifikasikan dengan metode Bi-LSTM yang akan digabungkan dengan salah satu pendekatan pembobotan kata yaitu *pre-trained word embeddings GloVe*.

## DAFTAR PUSTAKA

- [1] M. S. a. M. R. a. A. M. Saputri, "Emotion classification on indonesian twitter dataset," in *2018 International Conference on Asian Language Processing (IALP)*, IEEE, 2018, pp. 90--95.
- [2] V. R. Berhito, "Multi-label emotion detection in Twitter," 2017.
- [3] A. Das, "Multi-Label Emotion Classification with PyTorch + HuggingFace's Transformers and W&B for Tracking," [Online]. Available: <https://towardsdatascience.com/multi-label-emotion-classification-with-pytorch-huggingfaces-transformers-and-w-b-for-tracking-a060d817923>. [Accessed 10 November 2021].
- [4] J. a. P. B. a. H. G. a. F. E. Read, "Classifier chains for multi-label classification," *Machine learning*, vol. 85, pp. 333--359, 2011.
- [5] M. a. M. A. Jabreel, "A Deep Learning-Based Approach for Multi-Label Emotion Classification in Tweets," *Applied Sciences*, vol. 9, 2019.
- [6] D. a. J. X. a. L. J. a. L. S. a. Z. Q. a. Z. G. Zhang, "Multi-modal Multi-label Emotion Detection with Modality and Label Dependence," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 3584--3593.
- [7] A. R. a. K. K. A. Murthy, "A Review of Different Approaches for Detecting Emotion from Text," in *IOP Conference Series: Materials Science and Engineering*, IOP Publishing, 2021, p. 012009.
- [8] H. F. a. H. A. F. Fadli, "Identifikasi Cyberbullying pada Media Sosial Twitter Menggunakan Metode LSTM dan BiLSTM," *AUTOMATA*, vol. 2, 2021.
- [9] J. a. Pennington, "{G}lo{V}e: Global Vectors for Word Representation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing ({EMNLP})*, Association for Computational Linguistics, 2014, pp. 1532--1543.
- [10] D. a. M.-A. D. a. K. J. a. C. A. a. N. G. a. R. S. Demszky, "GoEmotions: A Dataset of Fine-Grained Emotions," in *58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.